UNIVERSIDAD NACIONAL DE INGENIERÍA

UNIDAD DE POSGRADO – FACULTAD DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS

INFORME PARCIAL
PROYECTO DE INVESTIGACIÓN II
PLAN DE TESIS Y PROTOCOLO DE INVESTIGACIÓN

DISEÑO, SIMULACIÓN Y EVALUACIÓN COMPARATIVA DE DDPG AUTÓNOMO Y ARQUITECTURAS HÍBRIDAS DDPG–LQR Y DDPG–ISMC PARA EL BALANCEO Y LA ESTABILIZACIÓN ROBUSTA DEL PÉNDULO INVERTIDO TIPO CART-POLE

Maestría en Inteligencia Artificial

Estudiantes: José Luis Espinoza Chamaya

Franklin Enrique Alegría Barboza

Asesor:

Docente del curso: Glen Dario Rodríguez Rafael

Lima, noviembre de 2026

Índice

PARTE I. PLAN DE TESIS 4
Datos generales 4
CAPÍTULO I. PLANTEAMIENTO DEL PROBLEMA 5
1.1 Diagnóstico 5
1.2 Justificación y alcances 8
CAPÍTULO II. OBJETIVOS 10
2.1 Objetivo general 10
2.2 Objetivos específicos 10
CAPÍTULO III. MARCO TEÓRICO 11
3.1 Bases teóricas 11
3.2 Definición de términos 11
3.3 Hipótesis y variables 14
CAPÍTULO IV. DISEÑO METODOLÓGICO 16
4.1 Tipo de investigación 16
4.2 Nivel de investigación 16
4.3 Métodos de trabajo 16
4.4 Población y muestra 17
4.5 Tipo de diseño 18
4.6 Técnicas e instrumentos de recolección de datos 18
4.7 Técnicas e instrumentos de análisis y procesamiento de datos 19
4.8 Etapas de intervención del estudio 19
CAPÍTULO V. ADMINISTRACIÓN DEL PLAN DE TESIS 21
5.1 Cronograma 21
5.2 Presupuesto 21
5.3 Financiamiento 21
PARTE II. PROTOCOLO DE INVESTIGACIÓN Y AVANCE EXPERIMENTAL 22
6. Datos y material de estudio 22
6.1 Origen, condiciones de uso y trazabilidad 22
6.2 Estructura, diccionario de datos y análisis exploratorio 22

6.3 Ética, privacidad y seguridad (si es necesario) 22
6.4 Preprocesamiento y control de fuga de información 22
7. Protocolo experimental 23
7.1 Preguntas de evaluación y criterios de éxito 23
7.2 Diseño de particiones y validación 23
7.3 Métricas y análisis estadístico 23
7.4 Baseline y variantes 24
7.5 Ingeniería de atributos o componentes 24
7.6 Optimización y presupuesto de búsqueda 25
7.7 Reproducibilidad y registro de experimentos 25
8. Resultados parciales y evidencia 26
8.1 Estado de implementación del pipeline 26
8.2 Comparación cuantitativa del baseline y variantes 26
8.3 Ablaciones y análisis de sensibilidad 28
8.4 Sobreajuste, errores y robustez 29
8.5 Interpretación y amenazas a la validez 29
9. Conclusiones del avance y próximos pasos 31
9.1 Conclusiones sustentadas por evidencia 31
9.2 Riesgos y plan de mitigación 31
9.3 Trabajo futuro y actividades de cierre 32
REFERENCIAS 33
ANEXOS 34
Anexo A. Matriz de consistencia 34
Anexo B. Procedimiento resumido de entrenamiento DDPG 34
Anexo C. Procedimiento resumido de evaluación híbrida 34
Anexo D. Registro de corridas 35
Anexo E. Gráficos de evaluación confirmatoria 35
Anexo E (continuación). Diferencias por semilla 36
Anexo F. Contraste complementario TD3 36

PARTE I. PLAN DE TESIS

Datos generales

Campo	Información
Título	DISEÑO, SIMULACIÓN Y EVALUACIÓN COMPARATIVA DE DDPG AUTÓNOMO Y ARQUITECTURAS HÍBRIDAS DDPG–LQR Y DDPG–ISMC PARA EL BALANCEO Y LA ESTABILIZACIÓN ROBUSTA DEL PÉNDULO INVERTIDO TIPO CART-POLE
Autores	José Luis Espinoza Chamaya Franklin Enrique Alegría Barboza
Unidad y programa	UNI · Unidad de Posgrado FIIS · Maestría en Inteligencia Artificial
Lugar de realización	Lima, Perú · entorno computacional de simulación
Duración	Campañas documentadas de 2026; cierre metodológico propuesto: diciembre de 2026
Asesor	Pendiente de confirmación en expediente institucional

CAPÍTULO I. PLANTEAMIENTO DEL PROBLEMA

1.1 Diagnóstico

El control del péndulo invertido tipo Cart-Pole presenta dificultades debido a su comportamiento dinámico no lineal y a la inestabilidad de su posición vertical superior. Para mantener el equilibrio, el controlador debe regular simultáneamente el movimiento del carro y la inclinación del péndulo, respetando los límites de desplazamiento y fuerza disponibles. Esta tarea se vuelve más exigente cuando el sistema parte de la posición inferior y debe realizar el levantamiento, estabilizarse y responder a perturbaciones externas.

En los experimentos realizados con el algoritmo de aprendizaje por refuerzo profundo DDPG se ha identificado una variabilidad considerable en los resultados del entrenamiento. Bajo presupuestos de entrenamiento comparables, algunas políticas aprendidas lograron superar los 110 segundos de estabilidad estricta, mientras que otras no consiguieron mantener el equilibrio de manera sostenida. Esta diferencia evidencia que el desempeño del controlador puede depender de factores como la inicialización aleatoria, la exploración, la configuración de hiperparámetros y la selección del modelo entrenado.

Como consecuencia, obtener una política DDPG con buenos resultados en una ejecución no garantiza que el aprendizaje produzca un desempeño similar en entrenamientos independientes. Asimismo, permanece la necesidad de determinar cómo se comportan los controladores ante perturbaciones de distinta intensidad. Frente a esta situación, la investigación evalúa las arquitecturas híbridas DDPG-LQR y DDPG-ISMC para establecer si la incorporación de reguladores locales permite mejorar la estabilidad sostenida, la recuperación y la consistencia del control respecto al DDPG autónomo.

1.1.1 Identificación y descripción del problema de estudio

El péndulo invertido tipo Cart-Pole constituye un sistema dinámico no lineal cuyo control representa un desafío debido a la inestabilidad de su posición vertical superior. El problema de estudio consiste en lograr que el péndulo se eleve desde su posición inicial inferior hasta la vertical superior y permanezca estabilizado, manteniendo simultáneamente controladas la posición y velocidad del carro, así como el ángulo y la velocidad angular del péndulo. Esta tarea se vuelve más compleja cuando el sistema recibe perturbaciones externas que pueden provocar oscilaciones, pérdida de estabilidad o la caída del péndulo.

En este contexto, la investigación busca determinar en qué medida el algoritmo de aprendizaje por refuerzo profundo DDPG, utilizado de manera autónoma, puede controlar el sistema y si su integración con reguladores LQR e ISMC permite mejorar la estabilización y la recuperación frente a perturbaciones. Para ello, se comparan las tres arquitecturas bajo condiciones experimentales equivalentes, considerando su capacidad de levantamiento, estabilidad sostenida, tiempo de recuperación y esfuerzo de control.

El sistema estudiado presenta cuatro variables de estado: posición del carro (x), velocidad del carro (v), ángulo del péndulo (θ) y velocidad angular (ω). Se considera θ = 0 en la vertical superior y θ ≈ π en la posición inferior, con una fuerza de control limitada a ±10 N, un paso de integración de 0,02 s y un horizonte de evaluación de 120 s. La estabilidad estricta exige cumplir simultáneamente |x| ≤ 0,20 m, |v| ≤ 0,10 m/s, |θ| ≤ 0,05 rad y |ω| ≤ 0,10 rad/s.

La investigación se desarrolla mediante simulaciones computacionales basadas en un modelo matemático del péndulo invertido, implementadas en Python con las bibliotecas Gymnasium y Stable-Baselines3. Este entorno virtual permite entrenar y evaluar los controladores DDPG, DDPG-LQR y DDPG-ISMC bajo diferentes condiciones de operación y perturbaciones externas. La validación experimental mediante un prototipo físico no forma parte del alcance de esta etapa de investigación.

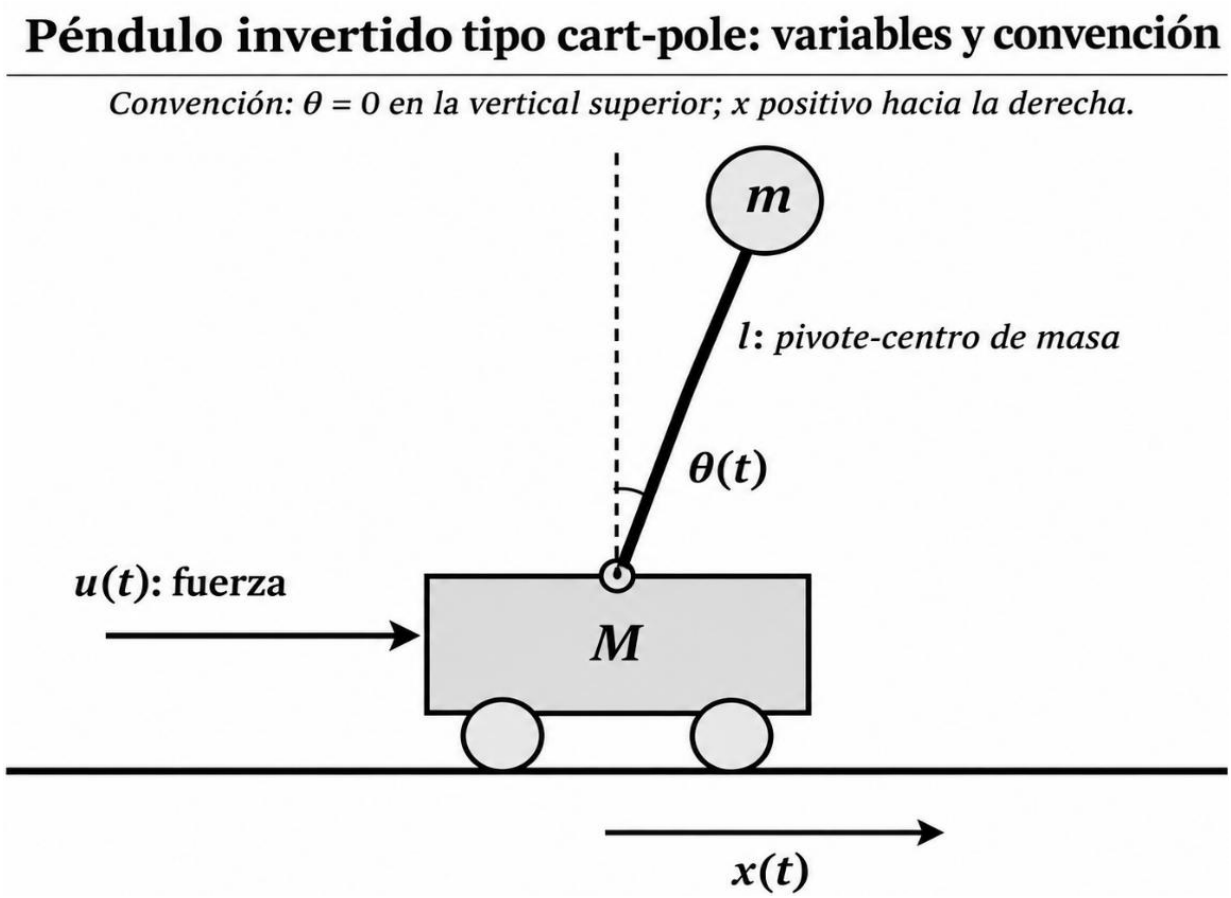


Figura P1. Modelo físico y convención angular del Cart-Pole.

1.1.2 Antecedentes de la investigación

Lillicrap et al. (2016) desarrollaron DDPG para políticas deterministas en espacios de acción continua mediante actor-crítico, memoria de experiencias y redes objetivo. Su estudio constituye el fundamento algorítmico de la política neuronal utilizada en la presente investigación.

Arévalo-Castiblanco et al. (2018) estudiaron los controladores LQR y por modos deslizantes (SMC) en plataformas pendulares. Evidenciaron su aplicación al control de sistemas dinámicos y aportaron una base para considerar métodos óptimos y robustos.

Fujimoto et al. (2018) propusieron TD3 para reducir problemas de sobreestimación en métodos actor-crítico mediante dos críticos, actualización retardada y suavizado de la política. Su contribución permite contextualizar las limitaciones de DDPG, aunque TD3 no constituye una de las tres arquitecturas que compara esta tesis.

Manrique Escobar et al. (2020) analizaron el aprendizaje por refuerzo profundo aplicado al balanceo (*swing-up*) del Cart-Pole y la sensibilidad del control a parámetros del sistema. Es un antecedente directo para formular el entorno y evaluar el comportamiento del controlador ante variaciones de la dinámica.

Shima y Bashir (2021) desarrollaron un controlador integral por modos deslizantes (ISMC), cuyos parámetros optimizaron mediante enjambre de partículas, para el balanceo y la estabilización de un carro-péndulo. Su estudio respalda la elección de ISMC como componente robusto, pero no evalúa su combinación con DDPG.

Hu et al. (2023) investigaron la aplicación de DDPG al control de un péndulo invertido mediante aprendizaje por interacción con un entorno. Su trabajo aporta evidencia de viabilidad del enfoque, sin establecer una comparación directa con arquitecturas DDPG–LQR o DDPG–ISMC.

Fu (2023) comparó DDPG, como método sin modelo, con una estrategia basada en identificación del sistema para controlar el Cart-Pole. El estudio evidencia que el aprendizaje por refuerzo no supera necesariamente a los enfoques basados en modelos y respalda una comparación experimental sin asumir superioridad previa.

Ma et al. (2023) abordaron el control robusto del péndulo invertido mediante iteración de políticas y formulación de control óptimo. Sus aportes relacionan aprendizaje, representación dinámica e incertidumbre, aspectos pertinentes para analizar la estabilidad bajo perturbaciones.

Pal et al. (2023) examinaron el efecto de las incertidumbres del modelo físico sobre la regulación de un péndulo invertido mediante aprendizaje por refuerzo. Este antecedente justifica incluir variaciones paramétricas y condiciones perturbadas, además de la simulación nominal.

Liu (2024) comparó DDPG, TD3, SAC y PPO en tareas simuladas de control continuo. Su análisis motiva el contraste exploratorio entre TD3 y DDPG, sin asumir que los resultados en otros entornos se trasladan directamente a este Cart-Pole.

Síntesis y vacío de investigación. Los diez trabajos revisados sustentan la aplicación de aprendizaje por refuerzo profundo al control continuo, el empleo de LQR e ISMC para estabilización local y la evaluación de perturbaciones. En este conjunto de referencias no se identificó una comparación conjunta de DDPG autónomo, DDPG–LQR y DDPG–ISMC con la misma planta Cart-Pole, políticas compartidas, condiciones emparejadas y métricas de estabilidad, recuperación y esfuerzo. El vacío delimitado es comparativo y metodológico, sin pretender demostrar una novedad absoluta frente a toda la literatura.

1.1.3 Formulación del problema

1.1.3.1 Formulación del problema general

¿Cuál es el desempeño comparativo de DDPG autónomo, DDPG–LQR y DDPG–ISMC para el balanceo, la estabilización estricta y la recuperación del Cart-Pole bajo condiciones nominales y perturbaciones externas comparables?

1.1.3.2 Formulación de los problemas específicos

¿En qué medida el controlador DDPG autónomo logra aprender una política de balanceo y estabilización del sistema Cart-Pole, considerando su desempeño y reproducibilidad entre diferentes semillas de entrenamiento?

¿Qué diferencias presentan los controladores DDPG autónomo, DDPG–LQR y DDPG–ISMC en la capacidad de balanceo, la precisión de estabilización y el tiempo de permanencia en equilibrio?

¿En qué medida la integración de LQR e ISMC con DDPG mejora la estabilidad y la robustez del sistema frente a perturbaciones externas de diferentes magnitudes?

¿Qué diferencias presentan las tres arquitecturas en el tiempo de recuperación, el error de estabilización y el esfuerzo de control bajo condiciones experimentales equivalentes?

1.2 Justificación y alcances

1.2.1 Justificación

El control del péndulo invertido tipo Cart-Pole constituye un problema representativo de los sistemas dinámicos no lineales, debido a las dificultades que presenta para realizar el balanceo, mantener la estabilidad y recuperar el equilibrio frente a perturbaciones externas. Aunque el aprendizaje por refuerzo profundo, mediante algoritmos como DDPG, permite desarrollar políticas de control continuo, su desempeño puede verse afectado por la variabilidad del entrenamiento y las condiciones de operación.

La presente investigación se justifica por la necesidad de evaluar si la integración de DDPG con controladores convencionales y robustos, como LQR e ISMC, permite mejorar el desempeño respecto a un controlador DDPG autónomo. Desde la perspectiva de la inteligencia artificial, se analizará la capacidad de aprendizaje y la reproducibilidad de las políticas obtenidas. Desde el control automático, se compararán la precisión de estabilización, la recuperación ante perturbaciones y el esfuerzo de control de las tres arquitecturas.

Asimismo, la investigación aporta una metodología de evaluación reproducible mediante simulaciones bajo condiciones experimentales equivalentes, diferentes semillas de entrenamiento y métricas cuantitativas. Los resultados permitirán identificar las ventajas y limitaciones de cada arquitectura, proporcionando evidencia para futuras investigaciones sobre control híbrido basado en aprendizaje por refuerzo.

1.2.2 Alcances

La investigación comprende el modelado matemático y la simulación no lineal del sistema Cart-Pole, el entrenamiento de un controlador DDPG autónomo y el diseño de dos arquitecturas híbridas: DDPG–LQR y DDPG–ISMC. Se evaluará su desempeño en tareas de balanceo, estabilización y recuperación frente a perturbaciones externas, considerando condiciones experimentales comparables.

Se realizarán pruebas de reproducibilidad entre semillas de entrenamiento, análisis de sensibilidad y experimentos de ablación para identificar la influencia de los componentes principales del sistema. Adicionalmente, se contempla una comparación exploratoria entre DDPG y TD3 como alternativa de aprendizaje por refuerzo profundo.

El estudio se limita a un entorno de simulación y no incluye implementación en sistemas físicos reales, demostración formal de estabilidad global ni comparación exhaustiva con otros algoritmos de aprendizaje por refuerzo. Por tanto, las conclusiones estarán restringidas a los modelos, escenarios y condiciones experimentales evaluados.

CAPÍTULO II. OBJETIVOS

2.1 Objetivo general

Diseñar, simular y evaluar comparativamente un controlador DDPG autónomo y dos arquitecturas híbridas DDPG–LQR y DDPG–ISMC para el balanceo, la estabilización y la recuperación del péndulo invertido tipo Cart-Pole, considerando la reproducibilidad del aprendizaje, la precisión de estabilización y la robustez frente a perturbaciones externas.

2.2 Objetivos específicos

Desarrollar y verificar un modelo matemático no lineal del sistema Cart-Pole que permita representar su dinámica y restricciones físicas en un entorno de simulación.

Diseñar y entrenar un controlador DDPG autónomo para realizar el balanceo y la estabilización del sistema Cart-Pole, evaluando su desempeño y reproducibilidad entre diferentes semillas de entrenamiento.

Analizar la influencia de los principales parámetros de entrenamiento y componentes del algoritmo DDPG sobre la estabilidad del aprendizaje y el desempeño del controlador, mediante análisis de sensibilidad y experimentos de ablación.

Diseñar e implementar las arquitecturas híbridas DDPG–LQR y DDPG–ISMC, integrando una política DDPG de balanceo con estrategias de estabilización local.

Comparar el desempeño de DDPG autónomo, DDPG–LQR y DDPG–ISMC en términos de éxito del balanceo, precisión de estabilización, tiempo de recuperación, esfuerzo de control y variabilidad de resultados, bajo condiciones nominales y perturbaciones externas equivalentes.

Evaluar exploratoriamente el algoritmo TD3 como alternativa a DDPG autónomo, comparando su desempeño y reproducibilidad del aprendizaje bajo condiciones experimentales equivalentes.

CAPÍTULO III. MARCO TEÓRICO

El sustento integra modelado mecánico, aprendizaje por refuerzo profundo y control local basado en modelos. El eje de la investigación es DDPG como política de fuerza continúa entrenada; LQR e ISMC se interpretan como complementos de estabilización, y TD3 como algoritmo comparador adicional.

3.1 Bases teóricas

El sistema Cart-Pole se modela con ecuaciones de Euler–Lagrange y estado $z=[x,v,\theta,\omega]$. DDPG aprende una política determinista $\mu(s)$ optimizada mediante crítico $Q(s,a)$, redes objetivo y replay buffer; en entrenamiento utiliza ruido exploratorio (Lillicrap et al., 2016). TD3 conserva el actor continuo e incorpora críticos gemelos, retardo del actor y ruido sobre acciones objetivo (Fujimoto et al., 2018). LQR usa el modelo linealizado alrededor de $\theta=0$ y una función de costo cuadrática; ISMC incorpora una superficie integral y componente robusta sujeta a límites de control (Khalil, 2002; Utkin, 1992). La conmutación no demuestra estabilidad global: se audita empíricamente en el conjunto de pruebas.

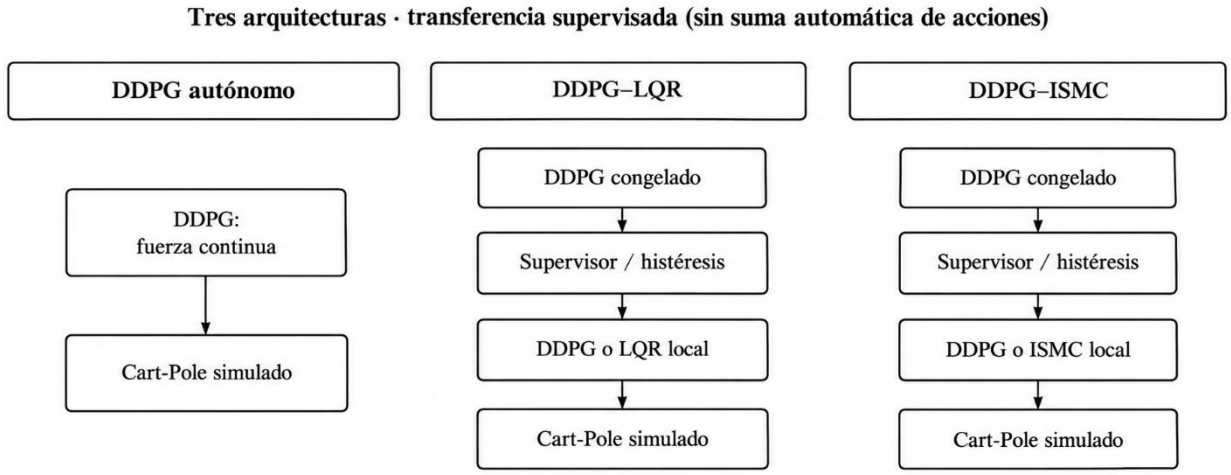


Figura 1. Arquitecturas de control estudiadas y marco común de evaluación comparativa.

Figura P2. Arquitecturas principales: DDPG autónomo y transferencia supervisada a LQR o ISMC (esquema conceptual).

3.2 Definición de términos

- **Cart-Pole:** sistema dinámico no lineal constituido por un carro que se desplaza horizontalmente y un péndulo articulado sobre él, cuyo movimiento se controla mediante una fuerza aplicada al carro.
- **Swing-up (balanceo):** maniobra de control que permite llevar el péndulo desde una posición alejada del equilibrio, generalmente la vertical inferior ($\theta \approx \pi$), hasta la región próxima a la vertical superior ($\theta \approx 0$).
- **Estabilización:** proceso mediante el cual un controlador mantiene el péndulo próximo a la posición vertical superior y limita el desplazamiento y la velocidad del carro.

- **Aprendizaje por refuerzo (RL):** técnica de aprendizaje automático en la que un agente aprende a tomar decisiones mediante su interacción con un entorno, buscando maximizar la recompensa acumulada (Sutton y Barto, 2018).
- **Agente:** sistema de aprendizaje que observa el estado del entorno y selecciona acciones de control de acuerdo con una política.
- **Entorno de simulación:** representación computacional del sistema físico que permite ejecutar acciones, calcular la evolución dinámica y obtener observaciones y recompensas.
- **Estado:** conjunto de variables que describen el sistema en un instante determinado. En el Cart-Pole puede incluir posición y velocidad del carro, ángulo y velocidad angular del péndulo.
- **Acción:** señal de control generada por el agente. En el Cart-Pole corresponde generalmente a la fuerza horizontal aplicada al carro.
- **Política:** función que determina la acción que debe ejecutar el agente a partir del estado observado.
- **Función de recompensa:** expresión matemática que asigna un valor a las consecuencias de las acciones del agente, orientando el aprendizaje hacia los objetivos de control.
- **DDPG (Deep Deterministic Policy Gradient):** algoritmo de aprendizaje por refuerzo profundo basado en una arquitectura actor-crítico que aprende políticas deterministas para espacios de acciones continuas.
- **Actor:** red neuronal que representa la política y genera acciones de control a partir del estado del sistema.
- **Crítico:** red neuronal que estima el valor esperado de ejecutar una acción en un estado determinado, orientando la actualización del actor.
- **TD3 (Twin Delayed Deep Deterministic Policy Gradient):** algoritmo derivado de DDPG que utiliza dos redes críticas, actualizaciones retardadas del actor y suavizado de las acciones objetivo para reducir errores de estimación y mejorar la estabilidad del aprendizaje.
- **LQR (Linear Quadratic Regulator):** estrategia de control óptimo basada en un modelo lineal que calcula acciones de control minimizando una función de costo cuadrática.
- **ISMC (Integral Sliding Mode Control):** técnica de control robusto por modos deslizantes que incorpora una superficie integral para mejorar el comportamiento del sistema frente a determinadas perturbaciones e incertidumbres.
- **Controlador híbrido:** arquitectura que combina dos o más estrategias de control. En esta investigación se integra DDPG para el balanceo con LQR o ISMC para la estabilización local.
- **Conmutación de controladores:** mecanismo que permite transferir el control entre DDPG y un regulador local cuando se cumplen condiciones previamente establecidas.
- **Hiperparámetros:** parámetros definidos antes o durante la configuración del entrenamiento, como la tasa de aprendizaje, el tamaño de lote y el factor de descuento.
- **Semilla de entrenamiento:** valor utilizado para inicializar los generadores de números pseudoaleatorios y facilitar la reproducibilidad de los experimentos.
- **Memoria de experiencias (Replay Buffer):** estructura que almacena transiciones de interacción del agente para reutilizarlas durante el entrenamiento.
- **Checkpoint:** registro de los parámetros y, cuando corresponde, del estado de entrenamiento de un modelo en una etapa determinada.

- **Currículo de entrenamiento:** estrategia que organiza progresivamente las condiciones o dificultades de aprendizaje para facilitar la adquisición de una política de control.
- **Ablación:** experimento controlado que consiste en retirar o modificar un componente del sistema para determinar su contribución al desempeño.
- **Análisis de sensibilidad:** procedimiento que evalúa cómo varían los resultados cuando se modifican parámetros o condiciones experimentales.
- **Perturbación externa:** fuerza o alteración aplicada al sistema que modifica su comportamiento dinámico respecto de las condiciones nominales.
- **Robustez:** capacidad del controlador para mantener o recuperar un desempeño aceptable frente a perturbaciones e incertidumbres dentro de un rango definido.
- **Estabilidad estricta:** condición experimental en la que se cumplen simultáneamente los límites establecidos para la posición y velocidad del carro, así como para el ángulo y la velocidad angular del péndulo.
- **Tramo estable máximo:** mayor intervalo continuo durante el cual se cumplen todas las condiciones de estabilidad estricta.
- **Ocupación estricta:** porcentaje del tiempo de evaluación durante el cual el sistema cumple simultáneamente las condiciones de estabilidad estricta.
- **Recuperación:** proceso mediante el cual el controlador devuelve el sistema a una región de estabilidad definida después de una perturbación.
- **Tiempo de recuperación:** intervalo transcurrido desde la aplicación de una perturbación hasta que el sistema vuelve a cumplir las condiciones de estabilidad establecidas, durante el tiempo mínimo exigido.
- **Esfuerzo de control:** medida de la magnitud o utilización de la señal de control aplicada al sistema durante un intervalo determinado.
- **Reproducibilidad del aprendizaje:** capacidad de obtener resultados consistentes al repetir el entrenamiento bajo un protocolo experimental definido, considerando la variabilidad entre semillas.
- **Evaluación emparejada:** procedimiento de comparación en el que diferentes controladores se someten a las mismas condiciones iniciales, perturbaciones y escenarios de prueba.

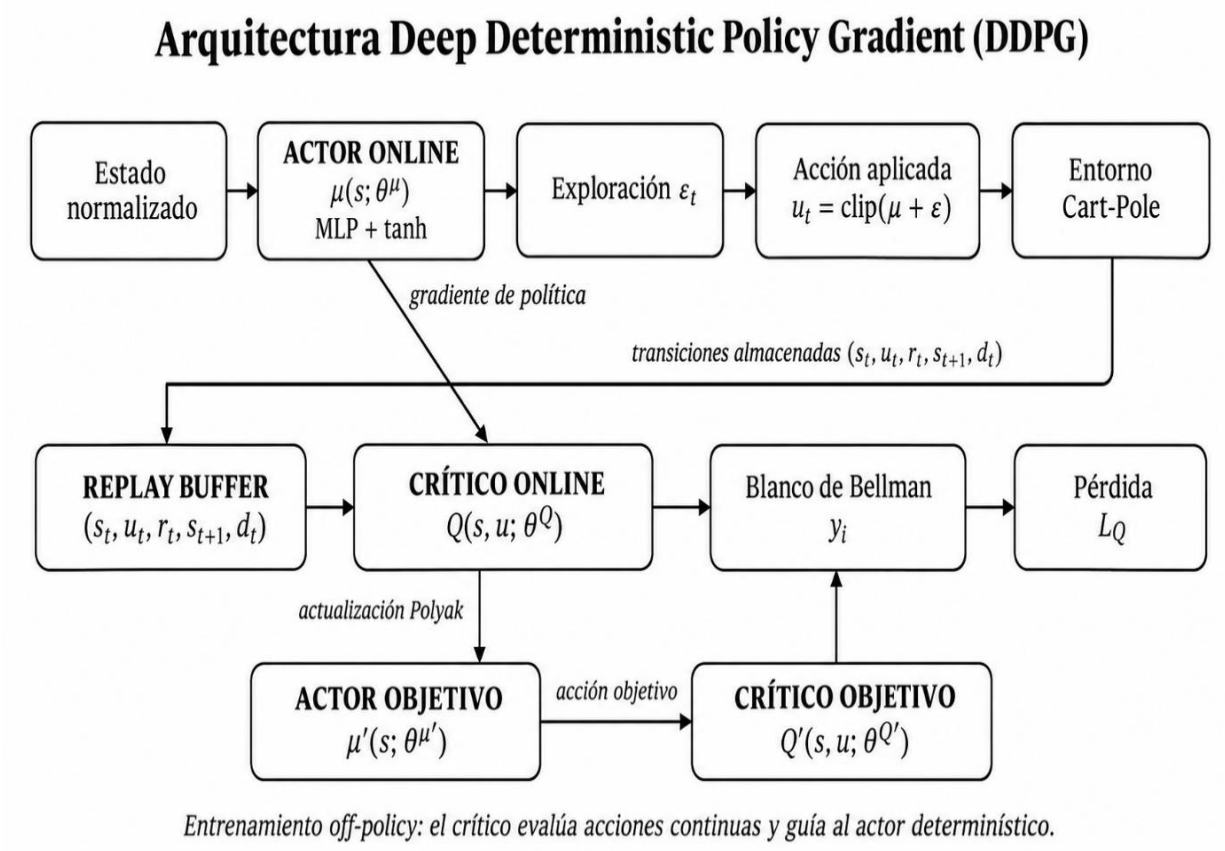


Figura P3. Actor, crítico y flujo de aprendizaje DDPG.

3.3 Hipótesis y variables

La investigación plantea hipótesis contrastables mediante simulaciones y métricas cuantitativas. La reproducibilidad del aprendizaje se evaluará utilizando semillas de entrenamiento independientes, mientras que la comparación de controladores se realizará bajo condiciones experimentales equivalentes. Se distinguirá entre las mejoras obtenidas durante el aprendizaje y aquellas producidas por la integración de controladores adicionales.

3.3.1 Hipótesis

H1. El algoritmo DDPG permite aprender políticas capaces de realizar el balanceo y la estabilización del sistema Cart-Pole, aunque su desempeño presenta variabilidad entre diferentes semillas de entrenamiento.

H2. Las arquitecturas híbridas DDPG–LQR y DDPG–ISMC presentan, en promedio, un mayor desempeño de estabilización que DDPG autónomo cuando se emplean políticas DDPG previamente entrenadas y congeladas, bajo condiciones experimentales equivalentes.

H3. Las variaciones en la configuración del entrenamiento y en los componentes del algoritmo DDPG producen diferencias medibles en la estabilidad del aprendizaje y el desempeño de las políticas obtenidas.

H4 (complementaria). El algoritmo TD3 presenta diferencias en el desempeño y la reproducibilidad del aprendizaje respecto a DDPG autónomo, bajo condiciones equivalentes de entrenamiento y evaluación.

3.3.2 Variables

Variables independientes

- Arquitectura de control: DDPG autónomo, DDPG–LQR y DDPG–ISMC.
- Configuración del aprendizaje: hiperparámetros, representación de estados, currículo de entrenamiento y estrategias de memoria de experiencias.
- Perturbaciones externas: magnitud, duración y momento de aplicación.
- Algoritmo complementario: TD3, para su comparación exploratoria con DDPG.

Variables dependientes

- Éxito del balanceo: porcentaje de episodios en los que el péndulo alcanza la región objetivo.
- Tiempo de estabilización: intervalo necesario para alcanzar y mantener las condiciones de estabilidad definidas.
- Tramo estable máximo: mayor intervalo continuo de estabilidad estricta, expresado en segundos.
- Ocupación estricta: porcentaje del tiempo durante el cual se cumplen simultáneamente las condiciones de estabilidad.
- Tiempo de recuperación: intervalo necesario para restablecer las condiciones de estabilidad después de una perturbación, expresado en segundos.
- Error angular: desviación respecto a la posición vertical superior, expresada en radianes.
- Esfuerzo de control: integral del cuadrado de la fuerza aplicada durante el episodio, expresada en $N^2 \cdot s$.
- Reproducibilidad del aprendizaje: variabilidad de las métricas de desempeño entre políticas obtenidas con diferentes semillas de entrenamiento.
- Costo de entrenamiento: cantidad de interacciones con el entorno y tiempo computacional requerido.

Variables de control

Se mantendrán constantes, según corresponda al experimento, los parámetros físicos del modelo Cart-Pole, las restricciones de fuerza y desplazamiento, la función de recompensa de referencia, el presupuesto de entrenamiento, las condiciones iniciales, el horizonte de simulación y los criterios de evaluación. Para la comparación de las arquitecturas híbridas se utilizarán políticas DDPG congeladas y escenarios de prueba emparejados.

CAPÍTULO IV. DISEÑO METODOLÓGICO

La investigación se desarrolla mediante simulación computacional y experimentación controlada con algoritmos de aprendizaje por refuerzo profundo. El procedimiento comprende el modelado matemático del péndulo invertido tipo Cart-Pole, el entrenamiento de políticas DDPG, la evaluación de estrategias para mejorar su aprendizaje y el diseño de dos arquitecturas híbridas, DDPG–LQR y DDPG–ISMC.

La metodología distingue dos líneas experimentales: la primera analiza el aprendizaje y la reproducibilidad del algoritmo DDPG; la segunda evalúa las mejoras de desempeño obtenidas al combinar políticas DDPG previamente entrenadas con controladores de estabilización local. Esta separación permite identificar los efectos del aprendizaje y diferenciarlos de los beneficios asociados a la integración de LQR o ISMC.

4.1 Tipo de investigación

La investigación es de tipo **aplicada**, con enfoque cuantitativo y experimental mediante simulación computacional (*in silico*). Su finalidad es diseñar y evaluar estrategias de control para un sistema dinámico no lineal, utilizando algoritmos de inteligencia artificial y técnicas de control automático.

El estudio emplea un entorno virtual que reproduce la dinámica del Cart-Pole mediante ecuaciones matemáticas. En este entorno se realizan experimentos de entrenamiento, estabilización y recuperación ante perturbaciones, sin requerir inicialmente la construcción de un prototipo físico.

4.2 Nivel de investigación

La investigación presenta un nivel explicativo-comparativo, porque analiza los cambios de desempeño asociados a diferentes arquitecturas y configuraciones de aprendizaje bajo condiciones experimentales controladas.

Asimismo, posee un componente descriptivo orientado a caracterizar el comportamiento del agente DDPG, su variabilidad entre entrenamientos y las limitaciones observadas en la simulación. Las conclusiones se restringen a los modelos, parámetros y escenarios evaluados.

4.3 Métodos de trabajo

El procedimiento metodológico comprende las siguientes actividades:

a) Modelado y simulación del Cart-Pole. Se desarrolló un modelo dinámico no lineal a partir de las ecuaciones de Euler–Lagrange, considerando cuatro variables de estado: posición y velocidad del carro, ángulo y velocidad angular del péndulo. Se incorporaron restricciones de fuerza, desplazamiento y perturbaciones externas. El entorno utiliza integración numérica con un paso principal de 0,02 segundos.

b) Diseño y entrenamiento del controlador DDPG. Se implementó un agente de aprendizaje por refuerzo profundo basado en una arquitectura actor-crítico, con acciones continuas correspondientes a la fuerza aplicada al carro. Se definieron observaciones, recompensas, mecanismos de exploración, memoria de experiencias y parámetros de entrenamiento. Durante las ejecuciones se almacenaron los modelos entrenados (*checkpoints*) para su posterior validación.

c) Evaluación y optimización del aprendizaje. Se realizaron campañas de experimentación identificadas como B–N6.1, donde se estudiaron modificaciones en la recompensa, hiperparámetros, exploración, representación del estado, currículo de entrenamiento y retención de experiencias. Se utilizaron pruebas de sensibilidad y ablación para analizar la influencia de estas configuraciones. Las validaciones independientes permitieron identificar mejoras individuales, variabilidad entre semillas y casos de degradación de políticas previamente exitosas. Como cierre de la línea de optimización de hiperparámetros se ejecutó la campaña H-LR, en la que se modificó exclusivamente la tasa de aprendizaje (3×10^{-4} frente a 1×10^{-4}), manteniendo constantes la recompensa R2, la dinámica, la arquitectura de red y el resto de hiperparámetros H02.

d) Diseño de las arquitecturas híbridas. Se implementaron DDPG–LQR y DDPG–ISMC mediante la integración de una política DDPG previamente entrenada con un estabilizador local. En ambas arquitecturas, DDPG se utiliza para aproximar el péndulo a la región vertical, mientras que un supervisor determina la transferencia del control a LQR o ISMC. Durante estas evaluaciones se mantienen congelados los pesos de DDPG para no confundir las mejoras del controlador híbrido con cambios en el aprendizaje neuronal.

e) Evaluación experimental. Se desarrollaron campañas H1–H4 para comparar las tres arquitecturas. Se analizaron condiciones nominales, perturbaciones externas, recuperación, estabilidad, esfuerzo de control y comportamiento de la conmutación. También se efectuaron pruebas con LQR e ISMC puros para examinar sus capacidades de estabilización local.

f) Comparación complementaria con TD3. Se contemplan las pruebas TD3-01, TD3-02 y TD3-03 como una línea exploratoria para estudiar una alternativa de aprendizaje frente a DDPG. Esta comparación se mantiene separada de la evaluación principal de las tres arquitecturas de control.

4.4 Población y muestra

La población de estudio está constituida conceptualmente por las trayectorias y respuestas posibles del sistema Cart-Pole simulado, bajo diferentes políticas de control, condiciones iniciales y perturbaciones.

La muestra experimental está conformada por políticas entrenadas, semillas independientes y episodios de evaluación.

En la campaña H3 se utilizaron ocho políticas DDPG procedentes de semillas de entrenamiento distintas, dos semillas de evaluación y cuatro escenarios experimentales. Esto produjo 64

episodios por arquitectura principal, equivalentes a 192 episodios para DDPG autónomo, DDPG–LQR y DDPG–ISMC. Además, se realizaron 16 episodios adicionales con controladores locales puros, alcanzando 208 episodios principales.

Para el análisis de la reproducibilidad del aprendizaje, la unidad experimental independiente es la política obtenida mediante una semilla de entrenamiento. Los episodios correspondientes a una misma política se consideran observaciones relacionadas y no entrenamientos independientes.

4.5 Tipo de diseño

Se utiliza un diseño experimental computacional con comparaciones emparejadas, en el que se controlan las condiciones del simulador y los escenarios de evaluación.

El diseño diferencia dos procedimientos:

- **Evaluación del aprendizaje:** se entrenan políticas DDPG con diferentes semillas y configuraciones para estudiar la variabilidad y los efectos de las modificaciones del entrenamiento.
- **Evaluación de arquitecturas:** se compara una misma política DDPG congelada funcionando de manera autónoma o integrada con LQR e ISMC, bajo condiciones iniciales y perturbaciones equivalentes.

Las campañas se clasifican según su propósito exploratorio o confirmatorio. Esta distinción evita utilizar resultados preliminares como evidencia definitiva de superioridad.

4.6 Técnicas e instrumentos de recolección de datos

La técnica principal es la observación computacional de las trayectorias generadas durante el entrenamiento y la evaluación de los controladores.

Se utilizan las siguientes herramientas:

- **Python y NumPy:** implementación del modelo dinámico y procesamiento numérico.
- **Gymnasium:** definición de la interfaz del entorno de aprendizaje, incluyendo estados, acciones, recompensas y condiciones de terminación.
- **Stable-Baselines3:** implementación de algoritmos de aprendizaje por refuerzo profundo.
- **Google Colab:** ejecución de experimentos computacionales.
- **Google Drive:** organización y conservación de los archivos experimentales.

Los instrumentos de recolección comprenden registros de entrenamiento, archivos CSV, checkpoints de redes neuronales, configuraciones experimentales y trazas temporales de posición, velocidad, ángulo, fuerza y recompensa.

La trazabilidad se mantiene mediante la identificación de campañas, semillas, configuraciones y archivos asociados a cada ejecución.

4.7 Técnicas e instrumentos de análisis y procesamiento de datos

Los resultados se procesan mediante técnicas estadísticas descriptivas y comparativas, agrupando las observaciones por arquitectura, semilla de entrenamiento y escenario experimental.

Los principales indicadores son el éxito del balanceo, la duración máxima de estabilidad estricta, el porcentaje de tiempo estable, el error angular, el tiempo de recuperación y el esfuerzo de control.

Para determinar la estabilidad estricta se consideran simultáneamente los siguientes límites:

- Posición del carro: $|x| \leq 0{,}20$ m.
- Velocidad del carro: $|v| \leq 0{,}10$ m/s.
- Ángulo del péndulo: $|\theta| \leq 0{,}05$ rad.
- Velocidad angular: $|\omega| \leq 0{,}10$ rad/s.

Las evaluaciones principales consideran episodios de hasta 120 segundos.

Se calculan medias, medianas, medidas de dispersión y diferencias emparejadas. En la campaña H3 se utilizaron contrastes exactos de inversión de signos sobre las diferencias agregadas por semilla de entrenamiento. La interpretación de los resultados considera tanto la magnitud de las diferencias como la incertidumbre estadística y las limitaciones del tamaño muestral.

Asimismo, se analizan los experimentos que no muestran mejoras, las políticas que pierden estabilidad durante el entrenamiento y los casos en los que no se logra recuperar el equilibrio.

4.8 Etapas de intervención del estudio

El desarrollo de la investigación se organiza en cuatro etapas principales.

Primera etapa: modelado y desarrollo del entorno de simulación. Se formularon las ecuaciones dinámicas del Cart-Pole, se implementó el entorno computacional y se establecieron las restricciones físicas y condiciones de evaluación.

Segunda etapa: desarrollo y evaluación del aprendizaje DDPG. Se entrenaron políticas de control continuo y se realizaron campañas de sensibilidad, ablación y optimización del entrenamiento. Las campañas B–N6.1 permitieron estudiar diferentes configuraciones y comprobar la variabilidad del aprendizaje.

Tercera etapa: integración y evaluación de controladores híbridos. Se desarrollaron las arquitecturas DDPG–LQR y DDPG–ISMC y se ejecutaron las campañas H1–H4. En H3, el tramo

máximo medio de estabilidad estricta alcanzó 30,19 segundos con DDPG autónomo, 69,65 segundos con DDPG–LQR y 71,82 segundos con DDPG–ISMC. Estos resultados corresponden a las condiciones simuladas de dicha campaña y no representan una mejora del entrenamiento interno de DDPG.

Cuarta etapa: análisis, validación y consolidación. Se recopilaron las métricas, se realizaron comparaciones emparejadas y se revisó la reproducibilidad de los resultados. Permanecen como actividades de cierre la verificación definitiva de la correspondencia entre las ecuaciones y el tratamiento de las fuerzas en el código, la consolidación documental de los experimentos y la revisión de las limitaciones metodológicas.

Los resultados permiten caracterizar la capacidad de DDPG para aprender el balanceo y evaluar los beneficios de incorporar controladores locales. Sin embargo, no establecen una superioridad universal de las arquitecturas híbridas ni demuestran transferencia directa a sistemas físicos reales.

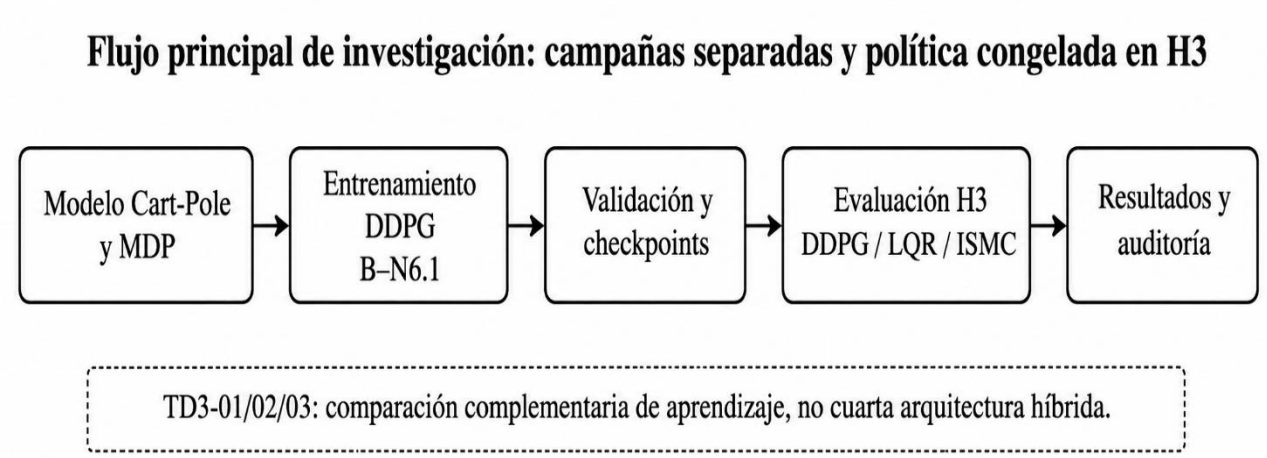


Figura P4. Flujo experimental: entrenamiento DDPG, selección de políticas y evaluación emparejada H3.

CAPÍTULO V. ADMINISTRACIÓN DEL PLAN DE TESIS

5.1 Cronograma

Actividad / hito	Semanas	Producto verificable
Modelado y políticas DDPG	Ejecutado en 2026	Entorno, R2 y checkpoints
Sensibilidad, ablaciones, TD3	Ejecutado hasta 12/11/2026	Resultados N4–N6.1 y TD3-01/02/03
Híbridos, auditoría y análisis	Ejecutado en 2026	H1–H4, contrastes y trazas
Revisión final de ecuaciones y bibliografía	Semanas 1–2 posteriores al parcial	Matriz de verificación y referencias revisadas
Integración formal UNI y anexos	Semanas 2–3 posteriores al parcial	Documento maestro revisado

5.2 Presupuesto

Rubro	Cantidad	Costo estimado
Software Python/SB3/Gymnasium	Código abierto; licencia específica por verificar	Sin costo de licencia reportado
Computación/Colab	Recursos propios y sesiones externas	Costo monetario no cuantificado
Almacenamiento y respaldo	Google Drive / archivos ZIP	Costo no cuantificado
Ensayos físicos	No realizados	No presupuestados en esta fase

5.3 Financiamiento

La investigación se ha desarrollado con recursos computacionales disponibles para el equipo y herramientas de software de código abierto, sin financiamiento externo declarado en el expediente revisado. Los costos monetarios de cómputo y almacenamiento quedan pendientes de cuantificación; no se afirma un presupuesto ejecutado de valor cero.

PARTE II. PROTOCOLO DE INVESTIGACIÓN Y AVANCE EXPERIMENTAL

6. Datos y material de estudio

Los datos son sintéticos: transiciones generadas por el propio simulador con condiciones iniciales y perturbaciones documentadas. No existe dataset externo de personas. La unidad de registro depende del archivo: paso temporal (0,02 s), episodio (hasta 120 s) o semilla de entrenamiento. Los resultados históricos y las nuevas campañas permanecen separados por versión experimental.

6.1 Origen, condiciones de uso y trazabilidad

Origen: código del entorno Cart-Pole desarrollado para la tesis y ejecuciones propias. Dependencias principales Python, NumPy, Gymnasium y Stable-Baselines3, sujetas a las versiones fijadas en notebooks de cada campaña. El material experimental contiene rutas, semillas, archivos de pesos, CSV y metadatos; no se declara una licencia externa que no consta en los registros. Corte del avance: 12 de noviembre de 2026.

6.2 Estructura, diccionario de datos y análisis exploratorio

Diccionario mínimo: x [m], v [m/s], θ [rad], ω [rad/s], u [N], perturbación externa [N], tiempo [s], recompensa R2 [adimensional], estabilidad máxima [s], ocupación [%], recuperación [s], esfuerzo [$N^2 \cdot s$], seed [entero], step [pasos], treatment/algorithm [categoría]. Para trazas de 120 s y $\Delta t = 0{,}02$ s son posibles 6000 transiciones por episodio; el tamaño total varía por terminaciones, campañas y selección de trazas. No se infiere un recuento único de datos de entrenamiento de la unión de ZIP.

6.3 Ética, privacidad y seguridad (si es necesario)

El estudio no procesa datos personales o sensibles: los registros describen un sistema mecánico simulado. Se conservan controles sobre archivos de Drive, integridad de modelos y acceso al repositorio; el consentimiento informado no aplica a estas trayectorias sintéticas.

6.4 Preprocesamiento y control de fuga de información

Se emplea la representación original de cuatro estados para comparaciones controladas. Las variantes normalizada y trigonométrica modifican solo la entrada según el experimento; sus escalas se definen sin usar resultados finales. Se separan semillas para entrenamiento, selección por validación y prueba final. En RL no corresponde dividir aleatoriamente pasos adyacentes de una trayectoria en train/test por riesgo de dependencia temporal.

7. Protocolo experimental

Se evaluó DDPG autónomo frente a sus variantes de entrenamiento, DDPG frente a los híbridos y DDPG frente a TD3 con condiciones equivalentes dentro de cada campaña. La métrica principal es estabilidad estricta continua máxima media por política; se reportan ocupación, recuperación, esfuerzo, tiempo de entrenamiento y evolución entre checkpoints. Los escenarios perturbados se conservan identificados por intensidad y duración.

7.1 Preguntas de evaluación y criterios de éxito

Éxito de control: aumentar el tramo estable medio dentro de las cuatro cotas estrictas sin usar estados iniciales privilegiados en la prueba completa. Éxito del aprendizaje: observar ventajas consistentes entre semillas nuevas y, cuando corresponda, menor número de interacciones para alcanzar umbrales. En TD3-03 se fijaron antes de ejecutar criterios de diferencia media ≥10 s, contraste bilateral $p<0,05$ y ventaja positiva en ≥6/8 semillas; no se cumplieron.

7.2 Diseño de particiones y validación

Conjunto / fold	Criterio de separación	Tamaño / período	Uso permitido
Entrenamiento	Semillas distintas de evaluación	Políticas independientes; 160K pasos en TD3-01/02/03	Ajuste de pesos y exploración
Validación	Semillas reservadas por campaña	5 semillas para seleccionar checkpoints	Selección de modelo; no inferencia final
Prueba reservada	Semillas no usadas para selección	10 episodios finales por política TD3	Reporte independiente
Híbridos H3	Semillas DDPG 801–803 y 901–905	8 semillas ×3 arquitecturas×4 escenarios×2 estados = 192 episodios	Comparación emparejada
H-LR entrenamiento	Semillas 41, 42 y 43; ramas pareadas desde R2-80K	6 ramas × 80K pasos adicionales (480K)	Ajuste fino con LR fijo por rama
H-LR validación	Semillas 6000–6004	5 episodios × 4 checkpoints (100K–160K) por rama	Solo selección de checkpoint
H-LR prueba reservada	Semillas 9100–9109, no usadas para seleccionar	10 episodios de 120 s por política seleccionada	Reporte final; no recalibra
Referencia k-fold	No implementada: episodios temporales dependientes	No corresponde declarar 5 folds	Validación por semillas/escenarios

7.3 Métricas y análisis estadístico

Métrica primaria: promedio, por semilla de entrenamiento, del tramo estricto máximo en segundos sobre episodios finales reservados. Secundarias: ocupación %, RMSE angular, recuperación posterior a perturbación, esfuerzo $\int u^2 dt$ y cumplimiento de cada una de las cuatro cotas. Se agregan primero episodios de una misma política y luego semillas. Para H3 se utilizaron contrastes pareados por semilla; los p-valores reportados corresponden a inversión de signos y deben interpretarse con cautela ante pruebas múltiples.

7.4 Baseline y variantes

ID	Modelo / configuración	Diferencia frente a baseline	Hipótesis de cambio
B0	DDPG-H02-R2	Referencia (4 estados; recompensa R2)	Capacidad y variabilidad del aprendizaje
A1	DDPG con representación sin/cos	Una transformación de observaciones	¿Mejora generalizable? N4/N4.1
A2	Currículo y retención 25 %	Distribución de estados o muestreo	¿Disminuye pérdida de desempeño? N5/N6
H1	DDPG-LQR / DDPG-ISMC	Se agrega estabilizador local con pesos DDPG fijos	¿Aumenta estabilidad? H3
C1	TD3-H02-R2	Doble crítico, retardo y smoothing	¿Mejora aprendizaje? TD3-01/03
L1	DDPG-H02-R2 con LR = 1×10^{-4}	Solo cambia learning_rate ($3\times10^{-4} \rightarrow 1\times10^{-4}$) en ajuste fino desde R2-80K	¿Una tasa menor reduce la pérdida de políticas? H-LR

7.5 Ingeniería de atributos o componentes

Las ablaciones de observación compararon cuatro estados originales frente a representación angular seno/coseno; las de currículo compararon inicio directo frente a entrenamiento por etapas; la retención comparó muestreo uniforme frente a reserva local 25 %. En híbridos, el contraste DDPG autónomo frente a DDPG+LQR/ISMC elimina o incorpora el componente estabilizador. Cambiar varios hiperparámetros simultáneamente es búsqueda conjunta y no ablación de un único factor.

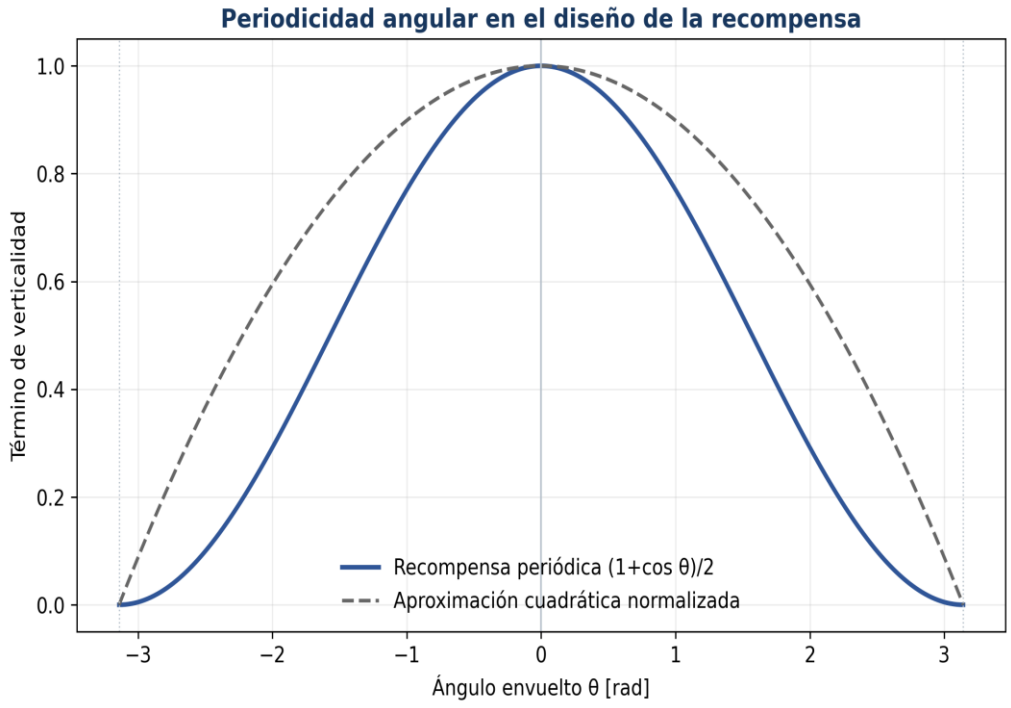


Figura P5. Recompensa angular: periodicidad y aproximación cuadrática.

7.6 Optimización y presupuesto de búsqueda

Parámetro	Rango / opciones	Estrategia	Presupuesto
learning_rate	3×10^{-4} (referencia H02) y 1×10^{-4}	Un factor a la vez; ajuste fino pareado desde R2-80K	3 semillas × 2 ramas × 80K = 480K pasos; H-LR
γ / τ	γ=0,995; τ=0,010 de base	Sensibilidad aislada	Series H–L
batch / ruido	128; σ=0,10 de base	Variantes y combinaciones	H–M3-A
observación	4 estados vs sin/cos 5D	Ablación independiente	N4 y N4.1
currículo / retención	4 etapas; reserva local 25 %	Control vs intervención	N5/N5.1; N6/N6.1
algoritmo	DDPG vs TD3, H02-R2 fijo	3+5+8 pares de semillas	TD3-01/02/03

7.7 Reproducibilidad y registro de experimentos

Se preservan notebooks, configuración H02-R2, semillas y checkpoints de 40K/80K/120K/160K, modelos seleccionados mediante validación, registros completos y ZIP de resultados en Google Drive. Para reproducibilidad plena deben guardarse versiones exactas de dependencias, hashes, hardware, estados aleatorios y memoria de repetición si se pretende reanudar entrenamiento a mitad de rama. Una desconexión no implica que un checkpoint aislado restituya exactamente el estado de aprendizaje. La campaña H-LR se encuentra en el repositorio github.com/Masterunia/Proyecto-TesisII (rama semana-8-optimizacion-ddpg) y registra Stable-Baselines3 2.9.2, Gymnasium 1.4.0, el hash SHA-256 del entorno original, la verificación de contador, γ, τ y lote de los modelos base y un manifiesto JSON con diseño, semillas y advertencias de interpretación.

8. Resultados parciales y evidencia

Corte experimental: campañas DDPG hasta N6.1; híbridos H1–H4; TD3-01, TD3-02 y TD3-03; y campaña H-LR de tasa de aprendizaje. Los resultados se presentan por protocolos separados para evitar agregar como si fueran una única muestra series históricas y confirmatorias. No se declara una ventaja TD3 confirmada ni una mejora del aprendizaje DDPG como efecto automático de LQR/ISMC.

8.1 Estado de implementación del pipeline

Implementado: simulador con perturbaciones, entrenamiento y selección por validación, registro de checkpoints, evaluaciones autónomas, híbridos con controles locales, campañas TD3 y análisis por semilla. Pruebas de auditoría ejecutadas: separación de semillas, conmutación, recuperación, controles locales sin DDPG y comparación de integridad de CSV/ZIP. Pendiente: transferencia física, estudio detallado de ruido e incertidumbre paramétrica y auditoría formal de equivalencia de algunas expresiones de fuerza histórica con el código.

8.2 Comparación cuantitativa del baseline y variantes

La Tabla P1 ofrece resultados agregados por semilla DDPG de entrenamiento, que es la unidad inferencial apropiada. No deben contarse los episodios de una misma política como observaciones independientes para estimar reproducibilidad. La Tabla P2 conserva los 16 pares de TD3 y DDPG: su comparación muestra tanto políticas exitosas como resultados nulos y desfavorables. Las figuras conceptuales provienen del documento maestro, mientras que los datos tabulados derivan de los CSV originales de las campañas.

Experimento	**Unidad experimental / réplica**	**Media / diferencia observada**	**Tiempo / coste**	**Decisión**
H3: DDPG	8 semillas; 64 episodios	30,19 s (estabilidad)	Sin reentrenamiento	Referencia híbridos
H3: DDPG–LQR	8 semillas; 64 episodios	69,65 s; Δ +39,46 s	Sin reentrenamiento	Mejora observada
H3: DDPG–ISMC	8 semillas; 64 episodios	71,82 s; Δ +41,63 s	Sin reentrenamiento	Mejora observada
N6 piloto	3 pares de semillas	94,414 vs 0,153 s	160K por entrenamiento	Exploratorio
N6.1 réplica	5 pares de semillas	18,444 vs 45,950 s	160K por entrenamiento	No replicó
TD3-01	3 pares	29,704 vs 0,079 s	160K por entrenamiento	Exploratorio
TD3-02	5 pares	23,189 vs 9,465 s	160K por entrenamiento	Inconcluyente
TD3-03	8 pares	42,395 vs 41,697 s	160K por entrenamiento	No confirmó TD3
H-LR: LR 3×10^{-4} (ref.)	3 semillas; 30 episodios	37,28 ± 62,75 s	80K pasos por rama (~8,4 min)	Referencia
H-LR: LR 1×10^{-4}	3 semillas; 30 episodios	35,73 ± 61,88 s; Δ −1,55 s	80K pasos por rama (~8,3 min)	No mejora; se mantiene 3×10^{-4}

En H3, la media del tramo estable máximo fue 30,19 s para DDPG, 69,65 s para DDPG–LQR y 71,82 s para DDPG–ISMC. Las diferencias medias emparejadas frente a DDPG fueron +39,46 s

y +41,63 s. Este resultado corresponde al desempeño del controlador compuesto con políticas congeladas, no a una mejora intrínseca del aprendizaje del actor.

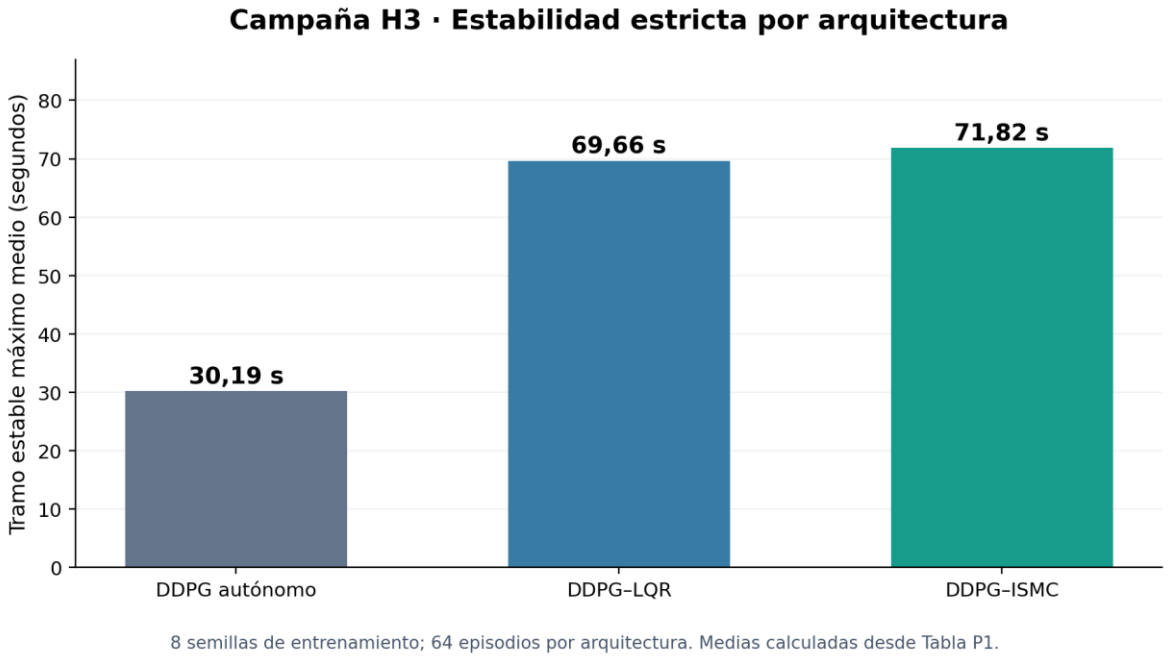


Figura P7. Comparación de estabilidad estricta media en H3 (datos de la Tabla P1).

La tabla siguiente resume episodios anidados en ocho políticas DDPG provenientes de semillas independientes; no equivale a 64 entrenamientos independientes por arquitectura.

Tabla P1. Campaña H3: estabilidad estricta por semilla de entrenamiento (s).

Semilla	DDPG	DDPG–LQR	DDPG–ISMC	Δ ISMC−DDPG
801	0,24	78,78	81,79	+81,55
802	0,00	79,34	82,08	+82,08
803	79,47	79,94	82,25	+2,78
901	79,84	79,75	82,16	+2,31
902	81,49	81,13	82,92	+1,43
903	0,01	79,81	82,06	+82,04
904	0,49	39,69	40,95	+40,47
905	0,00	38,80	40,38	+40,38

8.3 Ablaciones y análisis de sensibilidad

Componente cambiado	Control	Resultado	Interpretación
Estado angular	DDPG original 4D	N4 prometedor, N4.1 no replicó	No superioridad reproducible
Curriculum Learning	Inicio directo	N5 favorable en algunas semillas; N5.1 inconcluso	Efecto dependiente de semilla
Retención local 25 %	Muestreo uniforme	N6 +94,26 s; N6.1 −27,51 s	Ganancia inicial no confirmada
Estabilización local	DDPG autónomo congelado	H3: +39,46 s LQR / +41,63 s ISMC	Mejora del control, no del entrenamiento
Dos críticos / TD3 completo	DDPG-H02-R2	TD3-03: +0,70 s; p=0,9375	No identifica ventaja interna reproducible
learning_rate 3×10^{-4} → 1×10^{-4} (H-LR)	DDPG-H02-R2, mismo R2-80K y semilla	Δ −1,55 s; mejora en 1/3 semillas; p = 0,75	Efecto dependiente de semilla; sin mejora reproducible
γ, τ, lote, exploración	H02-R2	Mejoras aisladas sin confirmación	Análisis de sensibilidad; no ablación pura

Tabla P2. TD3-01/02/03: comparación emparejada de estabilidad por semilla (s).

Semilla	DDPG	TD3	Δ TD3−DDPG
1201	0,24	0,00	-0,24
1202	0,00	89,11	+89,11
1203	0,00	0,00	+0,00
1301	0,17	0,00	-0,17
1302	0,00	0,81	+0,81
1303	46,42	113,89	+67,47
1304	0,15	0,39	+0,24
1305	0,58	0,85	+0,27
1401	0,00	0,00	+0,00
1402	0,00	113,76	+113,76
1403	0,14	0,03	-0,10
1404	103,79	0,00	-103,79
1405	113,86	114,84	+0,98
1406	0,18	110,53	+110,35
1407	114,59	0,00	-114,59
1408	1,02	0,00	-1,02

Tabla P3. Campaña H-LR: estabilidad estricta en prueba reservada 9100–9109 por semilla de entrenamiento (s).

Semilla	LR 3×10^{-4}	LR 1×10^{-4}	Δ 1×10^{-4} − 3×10^{-4}
41	109,74	0,00	-109,74
42	0,98	107,18	+106,21
43	1,13	0,00	-1,13

Checkpoints elegidos solo por validación (6000–6004): con LR 3×10^{-4}, 160K en las tres semillas; con LR 1×10^{-4}, 100K en las semillas 41 y 43 (ningún checkpoint logró estabilidad estricta) y 160K en la 42. La ocupación estricta media fue 33,67 % con 3×10^{-4} y 29,79 % con 1×10^{-4}. Diferencia pareada media −1,55 s (DE 107,98 s; mediana −1,13 s); mejora en 1 de 3 semillas. El contraste exacto de inversión de signos da p = 0,75, y con n = 3 el menor p alcanzable es 0,25, por lo que la campaña es exploratoria. Fuente: prueba_reservada_9100_9109.csv (experimento_H_LR_DDPG_R2_resultados.zip).

8.4 Sobreajuste, errores y robustez

Se observaron políticas que superaron 100 s de estabilidad en un checkpoint y perdieron esa habilidad al continuar: N5.1 currículo semilla 902 pasó de 114,50 s (80K) a 0 s (160K) en validación. La política directa semilla 901 registró ~115,06 s (120K) y 0 s (160K). La retención del 25 % logró +94,26 s en piloto N6, pero −27,51 s en N6.1. En TD3-03, la política 1402 favoreció a TD3 y la 1404 a DDPG por más de 100 s, lo que revela inestabilidad entre semillas y la necesidad de reportar fallos. En H-LR, la tasa de aprendizaje baja no evitó la pérdida de desempeño: en las semillas 41 y 43 ningún checkpoint con 1×10^{-4} alcanzó estabilidad estricta, con RMSE angular de 1,70 y 3,00 rad y esfuerzo medio de 95,2 y 47,6 N², compatible con políticas que no capturan el péndulo. La selección por validación fue coherente con la prueba reservada (semilla 41 con 3×10^{-4}: 109,98 s frente a 109,74 s; semilla 42 con 1×10^{-4}: 110,42 s frente a 107,18 s), lo que indica que la variabilidad proviene del entrenamiento y no de la selección del checkpoint.

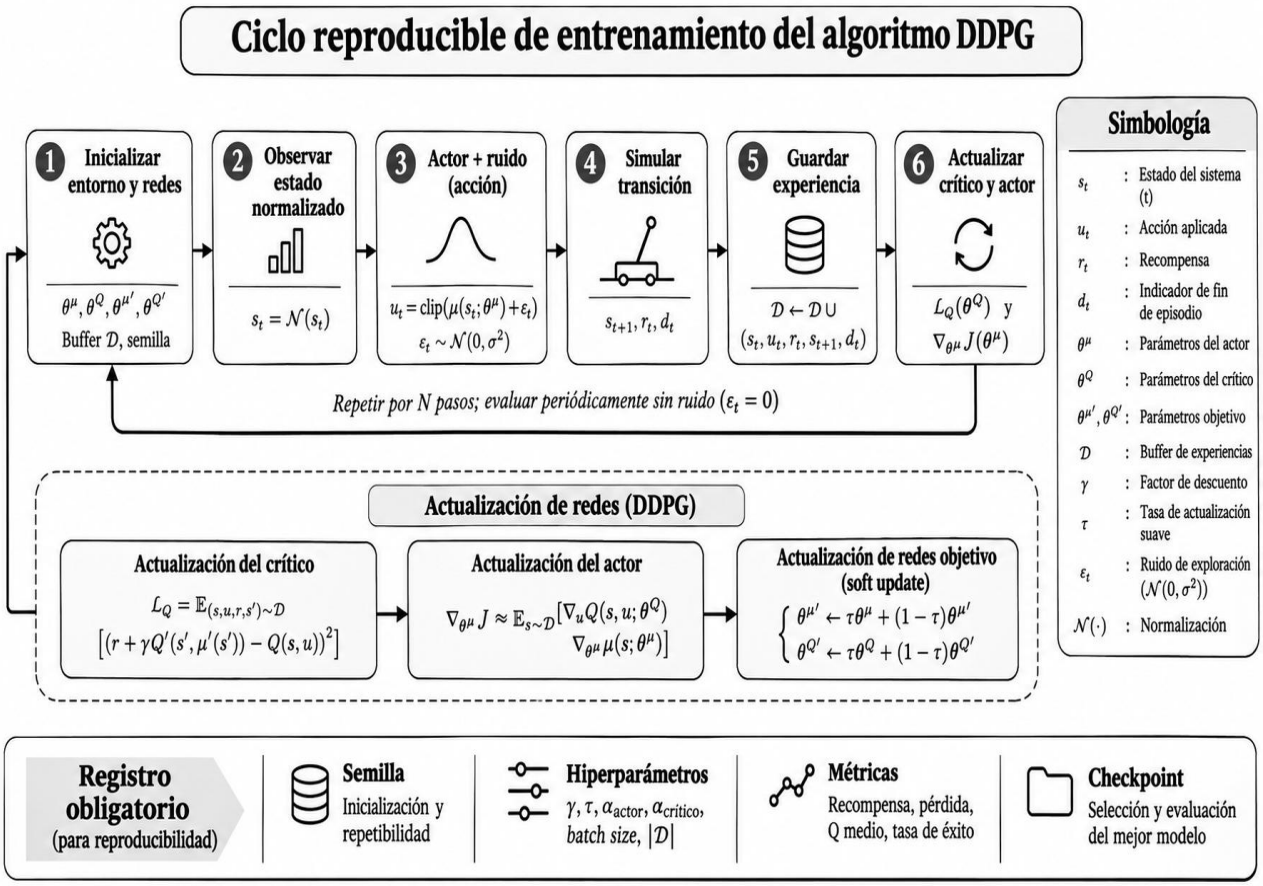


Figura P6. Ciclo de entrenamiento, checkpoints y evaluación de DDPG.

8.5 Interpretación y amenazas a la validez

Limitaciones: evaluación exclusivamente simulada, potencial sesgo de selección de checkpoints, número reducido de políticas independientes en algunas campañas y dependencia entre episodios de la misma política. H3 incorpora ocho semillas distintas de H1–H1.2; aun así, no es una prueba de estabilidad global. Los contrastes de H3 sobre tres arquitecturas requieren cautela

por multiplicidad. TD3 no permite concluir equivalencia con DDPG; la ausencia de evidencia de superioridad no es una prueba de igualdad. En H-LR las dos ramas de cada semilla comparten los primeros 80K pasos, por lo que se estima el efecto de la tasa de aprendizaje en ajuste fino y no en un entrenamiento completo; con n = 3 la potencia estadística es muy baja.

9. Conclusiones del avance y próximos pasos

El avance comprende evidencia de aprendizaje autónomo DDPG, pruebas controladas de sensibilidad y ablación, evaluación confirmatoria del beneficio híbrido y comparación complementaria con TD3. Las técnicas de optimización de DDPG mostraron ganancias individuales, pero no una configuración superior reproducible. Los híbridos elevaron la estabilidad media de H3 de 30,19 s (DDPG) a 69,65 s (DDPG-LQR) y 71,82 s (DDPG-ISMC). TD3 produjo políticas exitosas, sin confirmar superioridad frente a DDPG en TD3-03. La campaña H-LR tampoco identificó una tasa de aprendizaje superior a la de referencia.

9.1 Conclusiones sustentadas por evidencia

(1) DDPG demuestra capacidad de realizar swing-up y estabilización prolongada en determinadas semillas, pero la reproducibilidad sigue limitada.

(2) La normalización, representación angular, currículo y retención no confirmaron una mejora generalizable de su entrenamiento.

(3) DDPG-LQR y DDPG-ISMC mejoraron el desempeño medio de las políticas evaluadas sin modificar pesos neuronales; la mejora corresponde al sistema híbrido.

(4) TD3 superó la media de DDPG en pilotos, pero no la confirmación de TD3-03; por tanto no reemplaza a DDPG en esta tesis.

(5) Reducir la tasa de aprendizaje de 3×10^{-4} a 1×10^{-4} en ajuste fino (H-LR) no mejoró la estabilidad estricta media (−1,55 s; mejora en 1 de 3 semillas; $p = 0,75$). Se mantiene LR = 3×10^{-4} como referencia, sin declarar un valor óptimo.

9.2 Riesgos y plan de mitigación

Riesgo	**Impacto**	**Mitigación**	**Evidencia / responsable**
Semillas sensibles	Alto	Reportar réplicas, mediana y prueba final reservada	CSV H–N6, TD3
Pérdida de políticas entre checkpoints	Alto	Auditoría temporal y selección solo por validación	Auditoría N5/N5.1
Fuga de información	Alto	Separar train/valid/test por semillas	Manifiestos por campaña
Pseudorreplicación estadística	Alto	Agregación por semilla independiente	H2–H4
Sesgo de implementación de la fuerza	Medio	Auditar expresiones de saturación y perturbación	Código + ecuaciones
Sobrecosto y desconexión Colab	Medio	Guardado por rama, backup y verificación Drive	Checkpoints ZIP

9.3 Trabajo futuro y actividades de cierre

Actividad	Entregable	Criterio de aceptación	Fecha
Conciliar ecuaciones/código	Acta de consistencia matemática	Fuerza, saturación e integrador coinciden	Próximo sprint
Verificar bibliografía APA	Matriz fuente↔afirmación	Todas las citas consultables y completas	Próximo sprint
Consolidar figuras finales	Anexos y gráficos con nombres correctos	Toda cifra trazable a CSV	Próximo sprint
Revisar formato final UNI	Documento de tesis definitivo	Portada, índice, títulos y anexos correctos	Próximo sprint

REFERENCIAS

Arévalo-Castiblanco, M. F., Rodríguez-Garavito, C. H., Patiño-Forero, Á. A., & Salazar-Cáceres, J. F. (2018). Controlador LQR y SMC aplicado a plataformas pendulares. *Revista Iberoamericana de Automática e Informática Industrial, 15*(4), 374–383. https://doi.org/10.4995/riai.2017.9101

Fu, M. (2023). Control of the cart-pole system: Model-based vs. model-free learning. *IFAC-PapersOnLine, 56*(2), 11847–11852. https://doi.org/10.1016/j.ifacol.2023.10.588

Fujimoto, S., van Hoof, H., & Meger, D. (2018). Addressing function approximation error in actor-critic methods. *Proceedings of Machine Learning Research, 80*, 1587–1596. https://proceedings.mlr.press/v80/fujimoto18a.html

Hu, H., Chen, Y., Wang, T., Feng, F., & Chen, W. (2023). Research on the deep deterministic policy algorithm based on the first-order inverted pendulum. *Applied Sciences, 13*(13), 7594. https://doi.org/10.3390/app13137594

Khalil, H. K. (2002). *Nonlinear systems* (3rd ed.). Prentice Hall.

Lillicrap, T. P., Hunt, J. J., Pritzel, A., Heess, N., Erez, T., Tassa, Y., Silver, D., & Wierstra, D. (2016). *Continuous control with deep reinforcement learning*. International Conference on Learning Representations. https://arxiv.org/abs/1509.02971

Liu, S. (2024). An evaluation of DDPG, TD3, SAC, and PPO: Deep reinforcement learning algorithms for controlling continuous system. In *Proceedings of the 2023 International Conference on Data Science, Advanced Algorithm and Intelligent Computing*. Atlantis Press. https://doi.org/10.2991/978-94-6463-370-2_3

Ma, Y., Xu, D., Huang, J., & Li, Y. (2023). Robust control of an inverted pendulum system based on policy iteration in reinforcement learning. *Applied Sciences, 13*(24), 13181. https://doi.org/10.3390/app132413181

Manrique Escobar, C. A., Pappalardo, C. M., & Guida, D. (2020). A parametric study of a deep reinforcement learning control system applied to the swing-up problem of the cart-pole. *Applied Sciences, 10*(24), 9013. https://doi.org/10.3390/app10249013

Pal, A. K., Oveisi, A., & Nestorović, T. (2023). The effect of model uncertainties in the reinforcement learning based regulation problem: An experimental case study with inverted pendulum. *PAMM, 23*(4), e202300130. https://doi.org/10.1002/pamm.202300130

Shima, T. J., & Bashir, H. (2021). PSO-based integral sliding mode controller for optimal swing-up and stabilization of the cart-inverted pendulum system. *Nigerian Journal of Technological Development, 18*(2), 88–97. https://doi.org/10.4314/njtd.v18i2.2

Sutton, R. S., & Barto, A. G. (2018). *Reinforcement learning: An introduction* (2nd ed.). MIT Press. http://incompleteideas.net/book/the-book-2nd.html

Utkin, V. I. (1992). *Sliding modes in control and optimization*. Springer.

ANEXOS

Anexo A. Matriz de consistencia

Problema	Objetivo	Hipótesis (si aplica)	Variable	Indicador medible
¿DDPG resuelve swing-up?	Evaluar autonomía DDPG	Éxito en algunas políticas	Controlador: DDPG	Estabilidad s; capturas
¿Qué mejora entrenamiento?	Ablaciones y sensibilidad	Efecto no siempre reproducible	Variante de aprendizaje	Diferencia por semilla
¿Híbridos mejoran control?	Comparar DDPG, DDPG-LQR, DDPG-ISMC	H2 favorable	Arquitectura	Δ estabilidad s
¿TD3 supera DDPG?	Contraste por semillas independientes	No confirmado TD3-03	Algoritmo RL	Δ estabilidad s, p

Anexo B. Procedimiento resumido de entrenamiento DDPG

1. Inicializar el entorno, la configuración H02-R2 y una semilla de entrenamiento documentada.

2. Entrenar la política DDPG con exploración, memoria de experiencias y checkpoints identificables.

3. Seleccionar checkpoints usando exclusivamente las condiciones de validación asignadas.

4. Congelar la política seleccionada y evaluarla sobre escenarios reservados, registrando trayectorias y métricas.

Anexo C. Procedimiento resumido de evaluación híbrida

1. Cargar exactamente el mismo checkpoint DDPG para las tres arquitecturas que se comparan.

2. Ejecutar el supervisor documentado; aplicar DDPG o el estabilizador local según la condición de conmutación, sin inferir una suma de acciones.

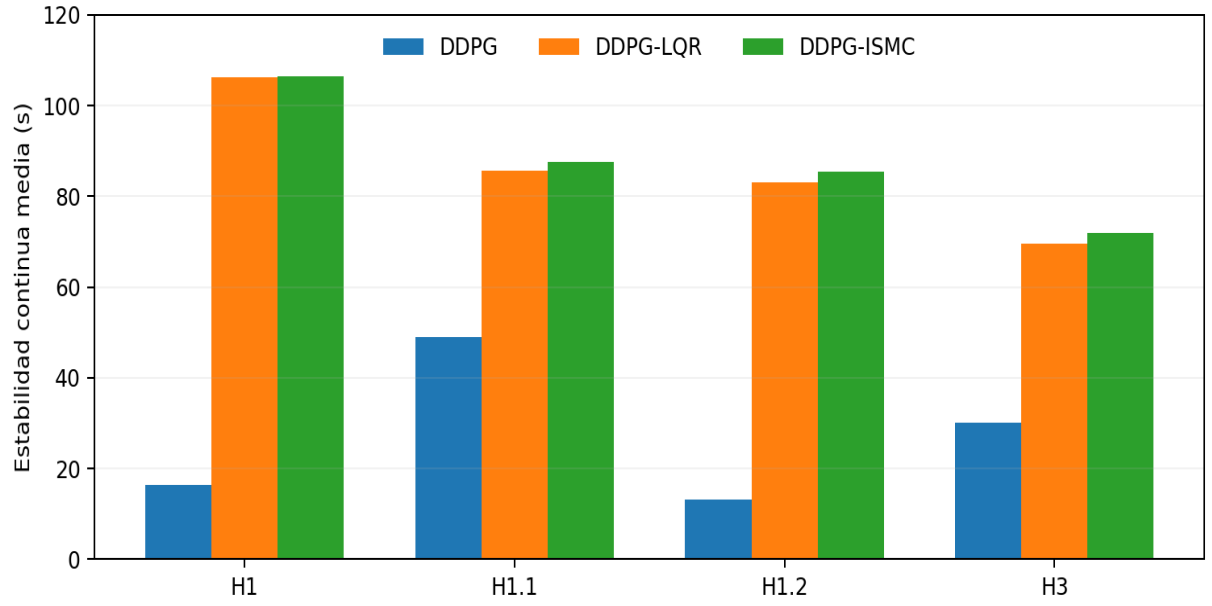
3. Mantener equivalentes los estados iniciales, perturbaciones, restricciones y criterios de evaluación.

4. Agregar resultados por política/semilla y documentar recuperación, estabilidad, esfuerzo y fallos.

Anexo D. Registro de corridas

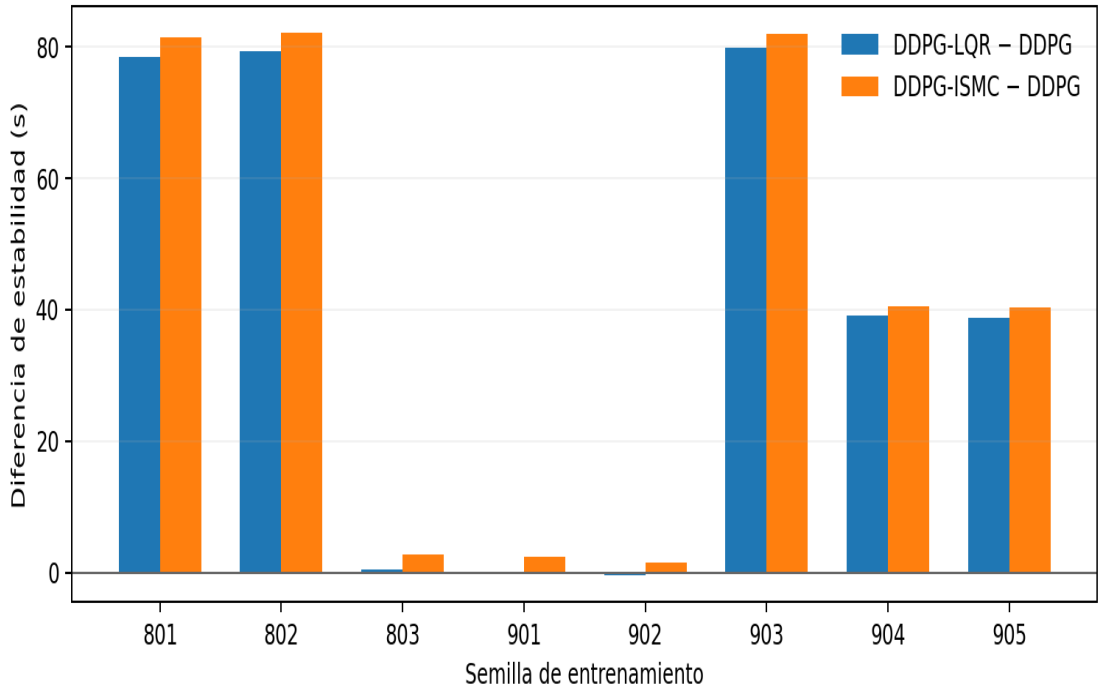
run_id	commit / datos	seed / split	métrica	artefacto
H3	CSV/ZIP de resultados	801–803;901–905	Δ estabilidad media	H3_CONFIRMACION_RESULTADOS.zip
N6/N6.1	ZIP por campaña	1001–1003;1101–1105	estabilidad y retención	Experimentos N6 / N6.1
TD3-01	CSV/ZIP	1201–1203	estabilidad máxima	TD3_01_COMPARACION_DDPG_R2_RESULTADOS.zip
TD3-02	CSV/ZIP	1301–1305	estabilidad máxima	TD3_02_VALIDACION_INDEPENDIENTE_RESULTADOS.zip
TD3-03	CSV/ZIP	1401–1408	p y Δ estabilidad	TD3_03_CONFIRMACION_FINAL_RESULTADOS.zip
H-LR	Git (rama semana 8)	41–43; 9100–9109	Δ estabilidad	experimento_H_LR_DDPG_R2_resultados.zip

Anexo E. Gráficos de evaluación confirmatoria



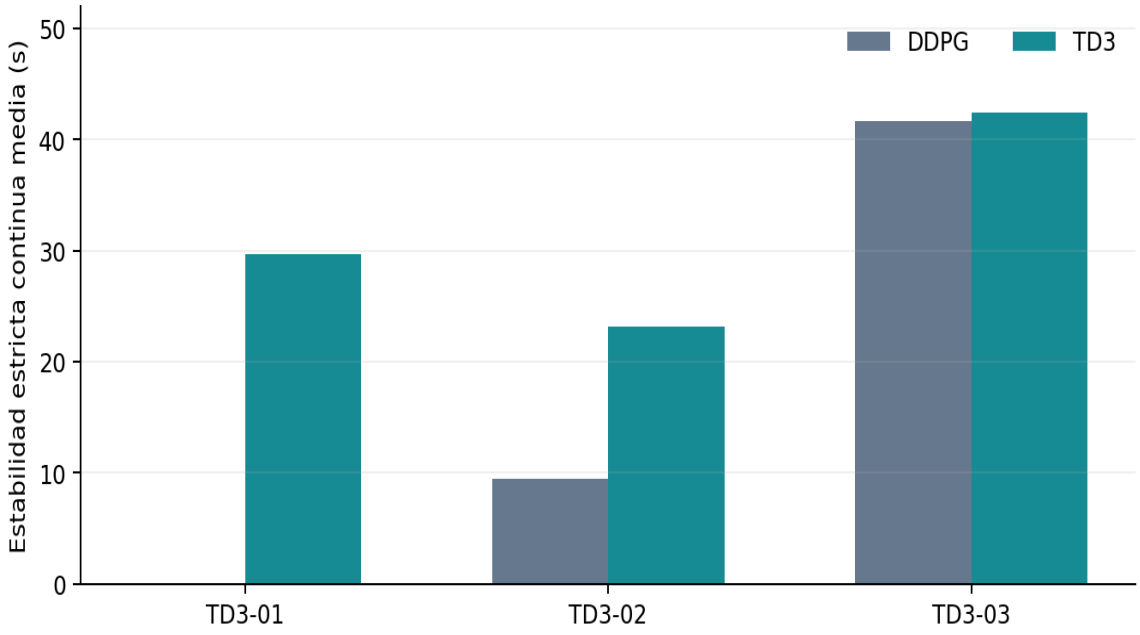
Fuente: cálculos derivados de los registros experimentales disponibles; sin validación física.

Anexo E (continuación). Diferencias por semilla



Fuente: cálculos derivados de los registros experimentales disponibles; sin validación física

Anexo F. Contraste complementario TD3



Fuente: cálculos derivados de la tabla de resultados TD3-01/02/03; no implica validación física.